BRIEFING DO PROJETO INTEGRADOR

Disciplina: Hands-On Fundamentos de Dados e Analytics
Módulo 1 – MBA em Engenharia de Dados – Universidade Presbiteriana Mackenzie
Mentoria: Prof. Gustavo Ferreira

---

1. IDENTIFICAÇÃO DO GRUPO

- **Nome do Projeto:** Bússola — Recomendação Personalizada de Destinos de Viagem
- **Setor de Atuação:** ☐ Varejo ☐ Saúde ☐ Finanças ☐ Logística ☐ Setor Público ☒ Outro: Turismo e viagens
- **Integrantes :**

Nome completo	**E-mail**
Renato de Oliveira de Souza	renatodeoliveiradesouza@gmail.com
Luciano Gomes da Silva	luciano.ggomess@gmail.com
José Carlos Marques	zecalife4@gmail.com

---

2. DESCRIÇÃO DO PROBLEMA DE NEGÓCIO

2.1 Qual é o problema que vocês pretendem resolver?

Plataformas de viagem costumam recomendar os mesmos destinos populares para todos os usuários, sem considerar o perfil de cada viajante: orçamento, época da viagem, experiências e paisagens desejadas, nível de atividade, preocupação com segurança e regiões de interesse. As sugestões acabam pouco relevantes: na base analisada, 61% das avaliações de destinos foram "Não" e 22% dos viajantes recusaram todos os destinos que viram.

2.2 Qual é o impacto do problema para o negócio?

A descoberta do destino é o início da jornada de compra de uma viagem. Sugestões pouco relevantes reduzem o engajamento, aumentam o abandono nessa etapa e diminuem a conversão em reservas. Além disso, um ranking apenas por popularidade entregaria os mesmos 3 destinos para todos os usuários, concentrando a demanda e deixando sem visibilidade a maior parte do catálogo de 1.452 destinos.

---

3. OBJETIVOS DO PROJETO

3.1 Objetivo Geral:

Desenvolver um sistema de recomendação baseado em Machine Learning que, a partir de um formulário de preferências, apresente os 3 destinos de viagem mais compatíveis com o perfil de cada usuário, com o grau de compatibilidade (Match) e o motivo de cada recomendação.

3.2 Objetivos Específicos:

- Construir um pipeline de dados no Databricks com as camadas Bronze, Silver e Gold (PySpark e Delta Lake), com tradução das respostas e flags de qualidade.
- Realizar a análise exploratória para entender o perfil dos viajantes, a distribuição das avaliações e a relação entre preferências e destinos aprovados.
- Treinar e validar um modelo de Regressão Logística com interações preferência × destino, comparando-o com a recomendação por popularidade e com um sorteio.
- Aplicar regras de negócio após o modelo: ajuste contra destinos "campeões", no máximo 1 destino por país e filtro pelas regiões escolhidas.
- Disponibilizar o Top 3 em uma aplicação web (Bússola) e para todos os viajantes cadastrados em uma tabela Delta.
- Documentar e versionar o projeto no GitHub, integrado ao Databricks.

---

4. DADOS UTILIZADOS

4.1 Fonte de Dados:

Stravl Travel Preference Data — base pública disponível em github.com/Stravl/stravl-data, liberada para uso acadêmico e comercial. Os dados foram anonimizados pela fonte (sem IP, nomes de usuário ou outros metadados pessoais).

4.2 Descrição da base:

- Número de registros: 80.301 viajantes (formulários) e 813.802 avaliações viajante × destino na camada Gold, sobre 1.452 destinos
- Número de atributos: 38 colunas na base original; 15 colunas na camada Gold
- Período coberto: não informado pela fonte (formulários e avaliações coletados pelo site Stravl, sem data por registro)

4.3 Principais variáveis:

Nome	Tipo	Significado	Tratamento necessário?
usuario_id	Texto (ID anonimizado)	Identificador do viajante	☐ Sim ☒ Não
destino	Texto	Destino avaliado (cidade, país)	☒ Sim ☐ Não Código convertido em nome pelo catálogo de destinos
pais	Texto	País do destino	☒ Sim ☐ Não Derivado do nome do destino; usado para região e diversidade
form_a_pt	Lista (múltipla escolha)	Faixas etárias do grupo	☒ Sim ☐ Não Tradução dos códigos; flag para quem marcou todas
form_b_pt	Lista (múltipla escolha)	Orçamento por pessoa/noite (US$)	☒ Sim ☐ Não Tradução; flag para quem marcou todas as faixas
form_c_pt	Lista (múltipla escolha)	Época da viagem	☒ Sim ☐ Não Tradução; exibida como período do ano (Dez–Fev etc.)
form_f_pt	Lista (múltipla escolha)	Experiências desejadas (praia, cultura...)	☒ Sim ☐ Não Tradução dos códigos
form_g_pt	Lista (múltipla escolha)	Paisagens desejadas	☒ Sim ☐ Não Tradução dos códigos
form_h_pt	Categórica	Nível de atividade	☒ Sim ☐ Não Tradução dos códigos

Nome	Tipo	Significado	Tratamento necessário?
form_i_pt	Categórica	Consciência de segurança	☒ Sim ☐ Não Tradução dos códigos
form_j_pt	Lista (múltipla escolha)	Popularidade desejada do destino	☒ Sim ☐ Não Tradução; flag para quem marcou todas
form_r_pt / form_rr_pt	Categórica / Lista	Para onde quer ir / regiões escolhidas	☒ Sim ☐ Não Tradução; flag de inconsistência geográfica
avaliacao	Categórica (Sim / Não / Talvez)	Resposta do viajante ao destino	☒ Sim ☐ Não Swipes repetidos contados uma vez; pares com respostas conflitantes descartados
target	Numérica (1 / 0 / nulo)	Variável-alvo do modelo	☒ Sim ☐ Não "Talvez" fica fora do treino

---

5. ARQUITETURA E GOVERNANÇA

5.1 Representação do fluxo de dados (camadas):

Ingestão (Bronze) → Preparação (Silver) → Armazenamento (Gold) → Visualização

Ingestão: o notebook 01_bronze lê o CSV de respostas e o catálogo de destinos do GitHub do Stravl (ou de um Volume) e grava em Delta, sem transformação, com colunas de rastreabilidade (fonte e data de ingestão).

Preparação: o 02_silver converte as respostas em listas, traduz os códigos para português, cria flags de qualidade e enriquece os destinos com país e região.

Armazenamento: o 03_gold consolida as 813.802 avaliações com o perfil de cada viajante em tabelas Delta no Unity Catalog (workspace.default); o 05 grava o Top 3 de cada viajante.

Visualização: o 04_eda gera as análises e gráficos, e a aplicação web Bússola (GitHub Pages) recebe o formulário e mostra o Top 3 com o Match de cada destino.

5.2 Simulação de camadas de dados:

Camada	Formato / ferramenta usada	Exemplo de conteúdo
Raw	Delta Lake no Databricks — bronze_stravl_formulario e bronze_stravl_destinos (origem: CSV e TXT)	Respostas em código ("['0', '2']"), listas de swipes ("[837, 779]") e os 1.486 nomes do catálogo de destinos
Trusted	Delta Lake (PySpark) — silver_stravl_viajantes e silver_stravl_destinos	Respostas traduzidas (["Praia","Cultura"]), flags de qualidade e destinos com país e região
Curated / Refined	Delta Lake — gold_stravl_v_2 e stravl_recomendacoes_top3	1 linha por avaliação viajante × destino com perfil e target; Top 3 de cada viajante com probabilidade

5.3 Princípios de Governança aplicados:

☒ Catálogo de dados

☒ Políticas de acesso

☒ LGPD (simulado)

☒ Classificação de sensibilidade

Catálogo de dados: tabelas organizadas no Unity Catalog por camada, com dicionário de dados (perguntas, códigos e traduções) documentado no repositório.

Políticas de acesso: permissões por usuário no workspace e no schema; credenciais do GitHub guardadas como token, nunca no código.

LGPD (simulado): a base já vem anonimizada (usuario_id é um identificador sem dados pessoais); o projeto não coleta nome, e-mail ou localização do usuário da aplicação.

Classificação de sensibilidade: dados classificados como públicos e não sensíveis; as respostas são preferências de viagem, sem dados pessoais ou sensíveis.

---

6. ANÁLISE EXPLORATÓRIA

6.1 Técnicas utilizadas:
☒ Estatística descritiva
☒ Visualização gráfica
☒ Detecção de outliers
☒ Correlação entre variáveis
☒ Análise de sazonalidade / clusterização
☒ Outras: análise de lift (destinos que cada perfil aprova mais que o restante dos viajantes) e personas por K-Means.

6.2 Ferramentas utilizadas:
☒ Python (Pandas / Seaborn / Matplotlib)
☐ R
☐ Power BI
☐ Tableau
☐ Google Looker Studio
☐ AutoML (especifique): _____

Também: PySpark e Delta Lake no Databricks (Serverless), scikit-learn para o modelo e MLflow para o registro dos experimentos.

---

7. MODELAGEM PREDITIVA

7.1 Tipo de problema modelado:
☒ Classificação ☐ Regressão ☒ Agrupamento

7.2 Algoritmo(s) utilizados:
☒ Regressão Logística ☐ Árvore de Decisão ☒ K-Means ☐ Random Forest

☒ Outro: regras de ranking após o modelo (ajuste de popularidade, diversidade por país e filtro de região)

7.3 Métricas utilizadas para validação:
☒ Accuracy ☒ Precision ☒ Recall ☒ F1 Score ☐ MAE ☐ RMSE

Resultados em viajantes de teste (nunca vistos pelo modelo): Accuracy 69,8% (responder "Não" para todos daria 63,4%), Precision 62,5%, Recall 43,8%, F1 Score 0,52 e AUC 0,737 (recomendação por popularidade: 0,708).

Métricas de ranking (o que importa para o app):
Precisão@3 de 52,7% (sorteio: 36,2%) e Acerto@3 de 70,0% — 7 em cada 10 viajantes têm pelo menos 1 destino aprovado no Top 3.

---

8. DASHBOARD FINAL

8.1 Ferramenta utilizada:

☐ Power BI ☐ Tableau ☐ Looker Studio ☒ Outro:
Aplicação web Bússola (HTML/JavaScript no GitHub Pages) e painel da análise exploratória

8.2 Público-alvo do dashboard:

☐ Diretoria ☒ Área de Negócio ☒ Stakeholders técnicos ☐ Equipe operacional

8.3 Principais KPIs apresentados:

KPI	Descrição	Valor atual	Meta ou insight
Precisão@3	Dos 3 destinos recomendados, % que o viajante aprovaria	52,7%	Supera o sorteio (36,2%) e empata com a popularidade (52,6%), mas com recomendações personalizadas
Acerto@3	% de viajantes com pelo menos 1 "Sim" no Top 3	70,0%	Sorteio: 60,4%
AUC	Capacidade de separar "Sim" de "Não"	0,737	Popularidade: 0,708; sorteio: 0,50
Destinos distintos recomendados	Variedade do catálogo nos Top 3 (viajantes de teste)	504	A popularidade recomendaria os mesmos 3 para todos
Taxa de "Sim" da base	Sim ÷ (Sim + Não)	36,7%	Base exigente: justifica exibir o Match relativo no app
Viajantes que recusaram tudo	% que disse "Não" a todos os destinos vistos	22%	Limita o acerto possível; sinal de perfis exigentes

---

9. DOCUMENTAÇÃO E APRESENTAÇÃO FINAL

9.1 Repositório GitHub do projeto (link):

https://github.com/renatodeoliveira101520/recomendador-viagens

Aplicação: https://renatodeoliveira101520.github.io/recomendador-viagens/

9.2 Componentes do repositório:

☒ README com visão geral

☒ Código-fonte (Python, SQL, etc.)

☒ Notebook técnico

☐ Slides de apresentação

☒ Artefatos complementares (ex: JSON, CSV, etc.)

9.3 Observações e aprendizados do grupo:

Personalização: uma regressão logística só com perfil e destino daria o mesmo ranking para todos; a solução foi incluir interações preferência × destino.

Destinos "campeões": Grécia, Itália e Japão agradam quase todos e dominavam as listas; criamos um ajuste de popularidade e a regra de 1 destino por país, que aumentaram a variedade de 189 para 504 destinos com perda de só 1 ponto de precisão.

Qualidade dos dados: a primeira versão da Gold não tinha 5 perguntas do formulário (atividade, segurança, popularidade e regiões); reconstruímos o pipeline a partir da base original e conferimos que a Gold gerada é idêntica, célula por célula.

Consolidação das avaliações: swipes repetidos e respostas conflitantes para o mesmo destino (1.331 pares) exigiram regras explícitas na Gold.

Interpretação: a "estação" do Stravl segue o hemisfério norte; no app passamos a mostrar o período do ano (Dez–Fev, Mar–Mai...) para evitar confusão.

Métricas: a acurácia sozinha engana em base desbalanceada; métricas de ranking (Precisão@3 e Acerto@3) e a comparação com a popularidade mostraram o valor real do modelo.

Engenharia: carga de arquivos no Databricks (o Excel subiu incompleto; Parquet resolveu), integração Databricks + GitHub via Git folder e publicação da aplicação no GitHub Pages.

Próximos passos: filtragem colaborativa com os swipes, atributos dos destinos (clima por mês, custo) e pipeline de CI/CD com Databricks Asset Bundles e Terraform.